

## 6.1 - O Neurônio e Seu Modelo Matemático

As Redes Neurais Artificiais foram desenvolvidas pelo neuro-fisiologista McCulloch e pelo matemático Pitts, que sugeriram usar elementos de hardware como resistores variáveis conectados a amplificadores, para se comportarem como os neurônios.

Em seguida, esperava-se conectá-los, formando uma rede capaz de emular a estrutura de funcionamento do cérebro humano. As redes neurais geraram uma grande expectativa, pois se acreditava que eles seriam capazes de emular exatamente o comportamento do cérebro humano, sendo capazes de raciocinar e resolver qualquer tipo de problema.


Contudo, em 1969, Minsk e Papert, demonstraram sérias limitações desta teoria e as redes neurais ficaram adormecidas até a década de 80, quando voltaram a atrair atenção da comunidade científica, com o surgimento de novos modelos e, desta vez, com um foco mais preciso sobre o tipo de problema que poderiam de fato resolver.

Embora as redes neurais possam ser usadas para resolver vários problemas práticos, a sua maior utilização é na resolução de problemas que podem ser classificados como reconhecimento de padrões, o que inclui uma ampla gama de aplicações como reconhecimento de voz, imagens (faces, impressões digitais) e objetos em geral.

Bom, antes de entender as redes neurais, vamos começar pelo neurônio biológico que foi a inspiração para o neurônio artificial.

O cérebro humano possui mais de 10 bilhões de neurônios, cada qual conectado, através de sinapses, a milhares de outros neurônios. Seu funcionamento ocorre de forma completamente diferente de qualquer computador digital, sendo considerado um processador de informação altamente complexo e que atua a maior parte do tempo em paralelo. Considerando o conceito numérico binário, se um cérebro humano fizesse apenas uma sinapse, seria capaz de registrar apenas dois estados (1 e 0). Se esse mesmo cérebro tivesse o dobro de sinapses, poderia realizar até quatro estados ( $2^2 = 4$ ). Esse processo se estende a  $n$  sinapses. Com apenas dez sinapses, por exemplo, chegaríamos a impressionantes 1.024 estados ( $2^{10} = 1.024$ ). Como existem aproximadamente 10 bilhões de neurônios ( $10^{10}$ ) e cada neurônio é capaz de criar até 10 mil sinapses ( $10^4$ ) com neurônios adjacentes, podemos concluir, de modo rudimentar, que o número de estados que o cérebro humano pode encapsular é igual a:  $10^{10} \times 10^4 = 10^{14}$ !

Os neurônios são elementos de processamentos muito simples, compostos por um soma, que é seu corpo, um axônio e vários dendritos, conforme a figura abaixo.



Os dendritos são responsáveis por receber os sinais de entrada dos demais neurônios. Quando a intensidade desses sinais ultrapassa determinado limiar, o neurônio é ativado, enviando um pulso elétrico ao axônio (saída) em direção às sinapses que o conecta aos demais neurônios.

Embora cada neurônio isoladamente seja muito simples, a enorme e complexa rede de neurônios que temos em nosso cérebro é capaz de processar informações de extrema complexidade a uma velocidade impressionante. Para o processamento de situações específicas (reconhecimento de padrões, controle motor), o cérebro humano excede, de longe, a velocidade de qualquer dispositivo computacional existente hoje em dia.


Mas como o cérebro consegue isso? Desde o nascimento, o cérebro tem a habilidade de estruturar seus neurônios e consequentemente o aprendizado através de um conjunto de regras que conhecemos mais comumente como experiência. A maior parte do desenvolvimento fisiológico dos neurônios e suas conexões (hardware) ocorrem até os dois anos de idade, mas todos sabem que o aprendizado vai muito além dessa idade.

O cérebro humano tem uma propriedade chamada *plasticidade*, o que significa que um determinado número de neurônios pode se reorganizar em resposta a eventos que ocorram, o que ocasiona o aprendizado. Plasticidade neuronal é o nome dado a essa capacidade que os neurônios têm de formar novas conexões a cada momento. Por isso, crianças que sofreram acidentes, às vezes gravíssimos, com perda de massa encefálica, deficits motores, visuais, de fala e audição, vão se recuperando gradativamente e podem chegar à idade adulta sem sequelas, iguais às crianças que nenhum dano sofreram.

O cérebro utiliza uma forma de atribuição de crédito que o induz a reforçar conexões entre neurônios que levem a soluções corretas para problemas e enfraquecer conexões que levem a soluções incorretas. A intensidade de uma sinapse determina qual será sua influência nos neurônios dessa conexão, o que implica que, se uma conexão for enfraquecida, seu papel será atenuado progressivamente nas computações seguintes.

As redes artificiais de neurônios são modeladas de forma análoga ao cérebro humano, sendo compostas por vários neurônios artificiais. O número de neurônios e de conexões entre estes tende a ser significativamente menor em termos de números do que o cérebro humano, embora possam chegar a milhares.

Visando simular o comportamento do neurônio biológico, McCulloch e Pitts (1943) propuseram o modelo de neurônio artificial ilustrado na figura abaixo.




Na imagem, temos o corpo do neurônio com suas entradas ( $E_i$ ) e saída ( $Y$ ). O corpo do neurônio é dividido em duas partes, sendo a primeira responsável por somar ( $\Sigma$ ) o produto das entradas  $E_i$  pelos seus respectivos pesos  $w_i$ . Na segunda parte, tem-se a função de ativação ou transferência ( $f$ ), que irá controlar o valor a ser enviado pela saída  $Y$ .

Além das entradas  $E_i$ , também se prevê uma entrada extra, chamada entrada viés (bias), que sempre tem como entrada o valor 1. Esta entrada não identificada nos neurônios biológicos, e opcional nas redes neurais artificiais, tem se mostrado muito útil em várias situações. A primeira parte do processamento, pode ser representada como:


$$net = \sum_{i=1}^n E_i * w_i + w_b$$

onde,  $E_i$  são as entradas da rede,  $w_i$  são os pesos associados às entradas e  $w_b$  é o peso da entrada viés (bias).

Para a função de transferência ou função de ativação  $f$ , existem várias possibilidades. As mais comuns são ilustradas na imagem abaixo:



Alguns modelos de redes neurais dependem da diferenciabilidade da função de transferência e, neste caso, as funções de transferência mais usadas são as ilustradas abaixo.



Estas diferentes funções de transferência têm aplicações diferentes nas redes neurais, sendo o mais comum encontrar:

- **Função Linear:** usada tipicamente para buffers de entrada e saída de dados (redes de Hopfield) e camadas ocultas.

- **Função Degrau e Degrau Unitário:** usadas em modelos como o Perceptron e também em redes de Hopfield.
- **Função Logística e Tangente Hiperbólica:** usadas em redes de alimentação adiante, usando o aprendizado Back Propagation.

